

# 哈尔滨工业大学深圳校区

## 毕业论文（设计）开题报告

题    目 基于轻量化神经网络的压缩  
信号重建研究

姓    名 宋逸涵

学    号 200210213

学    院 电子信息

专    业 通信工程

指 导 教 师 张行健

日    期 2023.11.4

## 目 录

1	课题背景及研究的目的和意义 .....	1
1.1	课题背景 .....	1
1.2	研究的目的和意义 .....	1
2	国内外研究现状及分析 .....	2
2.1	国内外研究现状 .....	2
2.2	国内外文献综述及简析 .....	2
2.2.1	压缩感知研究现状 .....	2
2.2.2	二值化神经网络研究现状 .....	3
3	主要研究内容及研究方案 .....	4
3.1	研究内容 .....	4
3.1.1	传统压缩感知理论 .....	4
3.1.2	生成模型重建信号 .....	4
3.1.3	二值化神经网络 .....	5
3.2	研究方案 .....	5
4	进度安排及预期目标 .....	7
4.1	进度安排 .....	7
4.2	预期目标 .....	7
5	已具备和所需的条件和经费 .....	8
5.1	实验室条件和经费保障 .....	8
5.2	所需条件和经费 .....	8
6	预计困难及解决方案 .....	9
6.1	预计困难与技术难点 .....	9
6.2	解决方案 .....	9
	参考文献 .....	10

# 1 课题背景及研究的目的和意义

## 1.1 课题背景

传统上，基于 Nyquist 采样定理，采样速率须达到信号带宽的两倍以上才能精确重构信号，这样的采样硬件成本昂贵，获取效率低下，对宽带信号处理的困难日益加剧。压缩感知技术能以远小于奈奎斯特频率采样信号，并高概率重建原信号，是信号处理领域里程碑式的进展。传统的压缩感知重建方法基于稀疏先验知识，通过解一个最优化问题，迭代地重建原始信号。这类方法存在两个主要问题：（1）自然图像等真实信号在变换域中并不精确满足稀疏性，而是可压缩信号，仅由稀疏性建模的重建算法应用于真实信号时重建精度下降。（2）由于重建算法采用多次迭代求解原信号，难以实现实时性，限制了压缩感知技术的应用广度和深度。

深度学习的迅速发展使研究者开始使用非人工设计的模型发展压缩感知重建算法。这些算法没有使用任何信号的先验知识，而是给神经网络提供大量的训练数据，由纯数据驱动算法学习如何最佳利用数据的结构，来加速重建过程。

## 1.2 研究的目的和意义

压缩感知虽然能以远小于奈奎斯特采样频率采样信号，但具有重建优化过程缓慢的缺点，面对现如今大规模的数据处理，传统的压缩感知无法得到广泛应用。于是研究者们将迅速发展的深度学习同压缩感知结合，通过使用单独训练的神经网络生成器，表现出的重建性能优于现有的 Lasso 方法。

同时，注意到轻量级模型的发展也能让神经网络更加高效，从而能够广泛地应用到各种场景任务中。在轻量化的神经网络模型中，二值化无疑是能最大程度地降低模型的存储占用和模型的计算量的研究方向。通过将激活、权重等浮点型数据转变为一比特位的数据，能够获得存储空间上的极大节省；同时，对二值化后的数据，原本的浮点乘加运算也变成了更为轻量化的 XNOR 和 Bitcount 位运算。二值化网络在节省内存、提高能源效率和加速运算方面效果更加显著。

考虑到传统压缩感知重建过程的缓慢，利用二值化神经网络与全精度网络精确度相当，训练速度却有大幅提升的优势，在 DCS 的过程中用二值化神经网络进行训练，提升整个压缩重建的速度，满足现今社会对实时性的要求。

## 2 国内外研究现状及分析

### 2.1 国内外研究现状

自压缩感知的理论提出，便在国内外掀起研究热潮，对统计学、信息论、编码论等科学领域具有重要的影响，并在模拟信息采样、合成孔径雷达成像、遥感成像、核磁共振成像、无线传感器网络、信源编码、人脸识别、语音识别等诸多领域展开了广泛的应用研究。目前压缩感知的应用场景有 CT 扫描、核磁共振、JPEG 类型图片的压缩、单像素相机等。

虽然神经网络二值化能够最大程度地降低模型的存储占用和模型的计算量，但会不可避免地导致严重的信息损失，其量化函数不连续性也给深度网络的优化带来了困难。近年来许多算法被提出致力于解决上述问题，并取得了令人满意的进展。

### 2.2 国内外文献综述及简析

#### 2.2.1 压缩感知研究现状

Candes、陶哲轩、Donoho 在[1]中提出以比奈奎斯特采样频率要求的采样密度更稀疏的密度对信号进行随机亚采样，由于频谱是均匀泄露的，而不是整体延拓的，因此可以通过特别的追踪方法将原信号恢复。随后他们给出了压缩感知的前提条件：信号的稀疏性<sup>[1]</sup>、观测矩阵和稀疏表示基不相关<sup>[2]</sup>。

基于信号稀疏性的前提，提出了大量的传统重建算法：（1）凸松弛方法<sup>[3]</sup>，将 NP 难的  $l_0$  范数求解问题转化  $l_1$  范数最小的凸优化问题。（2）贪婪匹配追踪方法<sup>[4]</sup>，基于贪婪策略每次迭代选择最合适原子并加入候选集的贪婪寻优方法。（3）贝叶斯类方法<sup>[5]</sup>，利用信号的先验概率分布，将重建问题转化成为概率求解问题。

随着深度学习的发展，研究者开始使用非人工设计的模型发展压缩感知重建算法。在文献[6]中，Bora 提出了使用生成模型的结构（变分自动编码器 VAE 和生成对抗性网络）进行压缩感知重建。生成模型用于压缩感知重建时，没有利用稀疏性作为先验信息，而是假设信号接近生成模型的值域，能得到与传统压缩感知类似的性能保证，且所需测量数低于凸优化方法。

使用生成模型压缩重建时需要数千个梯度下降步骤，优化仍然很慢；而且重建依赖于随机测量矩阵。在 Yan Wu, Mihaela Rosca, Timothy Lillicrap 等研究人员在 ICML 2019 发表的论文 Deep Compressed Sensing<sup>[7]</sup>中，基于前人将 CS 和神经网络生成器结合起来的方法，提出一个全新的框架：深度压缩感知 (DCS) 框架，

通过联合训练生成器和通过元学习优化重建过程，显著提高了信号恢复的性能和速度。

## 2.2.2 二值化神经网络研究现状

二值化神经网络的思想最初源于 2016 年 Yoshua Bengio 的论文《BinaryNet: Training Deep Neural Networks with Weights and Activations Constrained to +1 or -1.》<sup>[8]</sup>，它首次提出一种方法，可以用随机梯度下降的方式训练同时使用二值化的 weights 和 activations 的神经网络。

之后 Rastegari、Ordonez、Redmon、Farhadi 提出了 BWN (Binary Weight Networks) 和 XNOR-Net 模型<sup>[9]</sup>。BWN 只使用了二值化的 weights，而 activation 仍然采取的 float32 全精度，但是同全精度网络的效果相差不大。XNOR-Net 模型则对 weights 和 activations 都采取了二值化，并提出了用 scaling factor 恢复量化误差来提升精度的思想。

ABC-NET<sup>[10]</sup>针对二值化数据表达信息太弱的问题，提出使用多个二值化 weights 和 activations 线性加权求和的方式来近似表示全精度的 weights 和 activations。

MeliusNet<sup>[11]</sup>根据用 shortcut 和 concat 增强 Quality 和 Capacity 的指导思想设计了两个二值友好的模块，一个是 Dense Block，另一个是 Improvement Block，这两个模块在网络中每次都是交错出现，在整个信息流中不断地增强二值化 feature map 的信息表达，从而提升精度。

IR-Net<sup>[12]</sup>针对二值化在前向计算和反向梯度传播中带来的信息损失问题，分别提出了两个技术，一个是 Libra-PB (Libra Parameter Binarization)，用于在前向计算中同时最小化 weights 的量化损失和信息熵损失，另一个是 EDE (Error Decay Estimator)，通过渐进近似 sign 函数来最小化反向传播过程中梯度的信息损失。

在文献[13]中，作者在边缘设备上实现了 BNN 的训练。文中提出了针对 BNN 的前向和后向批量归一化 (Batch Normalization) 操作，实现了一个具有全二进制激活的神经网络训练模型；将二进制激活和二进制权重梯度成功组合，进一步减少了内存占用。

### 3 主要研究内容及研究方案

#### 3.1 研究内容

本课题的研究聚焦于传统的压缩感知算法以及使用神经网络与压缩感知相结合的 CSGAN 算法;在对已有的传统压缩感知模型和 CSGAN 模型进行探索研究后,还将结合轻量化网络中的 BNN 算法,让重构神经网络进一步的简化,加快训练速度,提高模型的实时性。

##### 3.1.1 传统压缩感知理论

传统的压缩感知理论主要包含有三个步骤:信号的稀疏表示、信号的观测和信号的重建,其数学模型为:

$$y = \Phi x$$

其中,  $x \in R^N$  为原始信号,  $\Phi \in R^{M \times N}$  为观测矩阵,  $\Phi$  的每一列称为原子,且  $M \ll N$ ,  $y \in R^M$  为测量向量。原始信号  $x$  可以在变换域中有稀疏表示:

$$x = \Psi s$$

其中,  $\Psi \in R^{N \times N}$  为稀疏表示矩阵,  $s \in R^N$  为  $x$  在变换域中的系数。若  $s$  至多有  $K$  个非零分量 ( $K \ll N$ ), 那么就称  $s$  是  $K$  稀疏信号,  $x$  在  $\Psi$  域中是  $K$  稀疏的。信号的线性观测则是将原始信号通过测量矩阵  $\Phi$  投影到一个低维空间, 这些低维空间中的投影需要包含足够多的信息, 通常由有限等距性质 (Restricted Isometry Property, RIP) 约束测量矩阵, 使原始信号能被高概率重建。从  $y$  恢复原始信号  $x$  的过程是压缩感知中最关键的部分——信号的重建, 其实质是求解一个 NP-Hard 的欠定问题:

$$\min \|s\|_0 \quad \text{s.t. } y = \Phi \Psi s$$

##### 3.1.2 生成模型重建信号

给定函数  $G: R^K \rightarrow R^N$  和  $z \in R^K$  的分布  $P_z$ , 可确定一个生成模型, 当隐变量  $z$  由分布  $P_z$  生成后, 可以输出样本  $G(z)$ 。由于  $K \ll N$ , 所以生成模型将低维表示空间映射到高维采样空间。模型的目标是在表示空间中找到一个向量  $z$ , 使对应的采样空间中的向量匹配观测值, 所以目标函数定义为:

$$\text{loss}(z) = \|\Phi G(z) - y\|^2$$

通过最优化过程, 能找到使  $\text{loss}$  最小的  $z$ 。假设生成模型可微, 则可以使用反

向传播估计  $loss$  的梯度，并采用标准的基于梯度的最优化方法。当优化终止在  $\hat{z}$  时，重建的信号为  $G(\hat{z})$ 。

### 3.1.3 二值化神经网络

在全精度卷积神经网络中，基本运算可以表示为：

$$z = \sigma(w \otimes a)$$

其中  $w$  和  $a$  分别表示网络层权重张量和之前的网络层生成的激活张量。 $\sigma(\bullet)$  表示非线性函数， $z$  表示输出张量， $\otimes$  表示卷积运算。在神经网络的正向推理过程中，卷积运算包含大量的浮点运算，包括浮点乘法和浮点加法，它们构成了神经网络推理中的绝大多数计算。

#### 3.1.3.1 二值化的前向传播

权重和激活二值化的函数：

$$Q_w(w) = \alpha b_w, Q_a(a) = \beta b_a$$

其中  $b_w$  和  $b_a$  代表二值化权重（卷积核）和二值化激活量的张量，相应的尺度因子分别为  $\alpha$  和  $\beta$ ，用于二值化得到  $Q_w$  和  $Q_a$  的是  $\text{sign}$  函数。

则卷积运算将变为：

$$z = \sigma(Q_w(w) \otimes Q_a(a)) = \sigma(\alpha\beta(b_w \odot b_a))$$

其中  $\odot$  表示由位运算 XNOR 和 Bitcount 实现的向量内积。

#### 3.1.3.2 二值化的后向传播

在训练一个二值神经网络时，可以直接采用基于梯度下降的强大的反向传播（BP）算法来更新参数。但是  $\text{sign}$  函数不可微，且可微处处为 0。Hinton 等人最早提出在反向传播中使用直通估计器（STE），用于解决训练中因为  $\text{sign}$  函数的导数几乎处处为 0 所产生梯度问题。

使用 STE 后，当  $\text{sign}$  函数的输入绝对值大于 1，将梯度置为 0；当输入的绝对值小于 1 时，将梯度置为 1，从而能使用梯度下降的方法来训练二值神经网络。

## 3.2 研究方案

神经网络的优化与改进好比一个黑盒问题，同时参数对神经网络训练的结果也有很大的影响。因此，将首先对压缩感知中的一些传统模型和使用深度学习的重建算法进行复现，基于损失率等指标探讨出不同模型的优缺点。接着，考虑减少神经网络的复杂度的问题，引入二值化的思想，对重建网络中的参数（权重、

激活、梯度等）进行从浮点数到一比特位的数据的替代，进一步比较二值化网络 and 全精度网络的准确度、存储、运行速度等指标，实现网络简化，使压缩重构的实时性得以优化，提高压缩感知技术的应用广度。

具体研究方案如下：

1. 建立信号模型，分别对信号为模拟信号与图片两种情况进行研究。
2. 复现实现传统压缩感知算法；
3. 实现基于生成对抗网络的压缩感知信号重建；
4. 利用二值化神经网络优化重建过程，完成生成对抗网络的网络简化。



## 4 进度安排及预期目标

### 4.1 进度安排

本课题的研究时间为 2023 年 9 月开始至 2024 年 5 月份进行答辩，根据之前的项目经验，结合自身学习，科研攻关能力，针对课题研究计划，制定出下面的研究进度：

1. 2023 年 11 月至 2024 年 1 月：对相关论文进行研读与复现，理解其中提出的算法。

2. 2024 年 1 月至 2024 年 4 月：建立一个将压缩感知与二值化网络结合的模型，通过对 MNIST、ImageNet、CIFAR-10 等各种数据集进行训练，在调整参数、改进算法后验证模型的优越性。

### 4.2 预期目标

预期目标是将压缩感知与二值化网络结合起来，实现压缩感知模型的压缩，提高模型的实时性。本课题预期实现下面两个目标和成果：

1. 完成[3]、[4]、[5]等介绍传统压缩感知重建算法的论文的结果复现，验证论文中提及算法的正确性；

2. 完成[6]、[14]中提及的使用生成对抗网络进行压缩感知信号重建算法的复现，体会加入神经网络后对重建误差、所需测量参数等方面的提升。

3. 对生成对抗网络进行简化，综合二值化网络和 CSGAN 进行压缩重建。在使用二值化网络实现生成对抗网络后，将对重建网络的存储占用、训练时长等方面有更大的提升，让自行设计的压缩感知模型更能满足实时性系统的要求。

## 5 已具备和所需的条件和经费

### 5.1 实验室条件和经费保障

配置有 python 环境的计算机，安装 tensorflow 和 keras 框架，下载安装与神经网络训练相关的包和数据库等。

### 5.2 所需条件和经费

使用计算机仿真，利用 tensorflow 和 keras 框架进行神经网络的训练。

## 6 预计困难及解决方案

### 6.1 预计困难与技术难点

本课题主要集中在神经网络模型的训练上。但神经网络模型的仿真实现和环境的搭建、参数的设置等有着密切的关系，参数的小小改动以及环境的不匹配都可能导致仿真结果出现较大的差异。因此复现过程中会出现与预期结果不太相同的问题；神经网络的输入是经过压缩后的数据，同时训练的过程中又采用了 BNN 训练，可能会导致最终输出准确度的进一步降低。

### 6.2 解决方案

为了提高课题进展速度和效率，保证学习质量，采用边应用边学习再应用的方法进行主要知识的系统学习，并多动手实际操作，对算法进行仿真，提高动手能力，也为后期打下良好的基础。同时采取以下方案：

- 1.对于在复现过程中出现的与论文结果不太相符的问题，要注意代码实现的环境，还有各种参数的设置，同时根据结果适当的调整参数。
- 2.当压缩信号经过二值化神经网络训练后准确度较低，应当集中对前向和反向传播进行优化与改进<sup>15</sup>，调整前向与反向传播中权重、激活、梯度等参数是否进行二值化，评估最终结果的优劣。
- 3.深度学习是一个快速发展的方向，在进行复现探索的过程中，还要积极关注国内外的相关论文，适时的对研究过程和方案做出改进与优化，也有助于解决出现的一些问题。

## 参考文献

- [1] Candès, E. J., Romberg, J. & Tao, T. Robust uncertainty principles: Exact signal reconstruction from highly incomplete frequency information. *IEEE Transactions on information theory* **52**, 489-509 (2006).
- [2] Baraniuk, R. G. Compressive sensing [lecture notes]. *IEEE signal processing magazine* **24**, 118-121 (2007).
- [3] Moshtaghpour, A., Jacques, L., Cambareri, V., Degraux, K. & De Vleeschouwer, C. Consistent basis pursuit for signal and matrix estimates in quantized compressed sensing. *IEEE signal processing letters* **23**, 25-29 (2015).
- [4] Nguyen, N., Needell, D. & Woolf, T. Linear convergence of stochastic iterative greedy algorithms with sparse constraints. *IEEE Transactions on Information Theory* **63**, 6869-6895 (2017).
- [5] Ji, S., Xue, Y. & Carin, L. Bayesian compressive sensing. *IEEE Transactions on signal processing* **56**, 2346-2356 (2008).
- [6] Bora, A., Jalal, A., Price, E. & Dimakis, A. G. in *International conference on machine learning*. 537-546 (PMLR).
- [7] Wu, Y., Rosca, M. & Lillicrap, T. in *International Conference on Machine Learning*. 6850-6860 (PMLR).
- [8] Courbariaux, M., Hubara, I., Soudry, D., El-Yaniv, R. & Bengio, Y. Binarized neural networks: Training deep neural networks with weights and activations constrained to+ 1 or-1. *arXiv preprint arXiv:1602.02830* (2016).
- [9] Rastegari, M., Ordonez, V., Redmon, J. & Farhadi, A. in *European conference on computer vision*. 525-542 (Springer).
- [10] Lin, X., Zhao, C. & Pan, W. Towards accurate binary convolutional neural network. *Advances in neural information processing systems* **30** (2017).
- [11] Bethge, J., Bartz, C., Yang, H., Chen, Y. & Meinel, C. Meliusnet: Can binary neural networks achieve mobilenet-level accuracy? *arXiv preprint arXiv:2001.05936* (2020).
- [12] Qin, H. *et al.* in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2250-2259.
- [13] Wang, E. *et al.* in *Proceedings of the 5th international workshop on embedded and mobile deep learning*. 37-38.
- [14] Jalal, A., Liu, L., Dimakis, A. G. & Caramanis, C. Robust compressed sensing using generative models. *Advances in Neural Information Processing Systems* **33**, 713-727 (2020).
- [15] Qin, H. *et al.* Binary neural networks: A survey. *Pattern Recognition* **105**, 107281 (2020).